

Эмпирические байесовские нейронные сети

Басов Дмитрий Константинович

Аннотация

Данная статья посвящена применению техники эмпирического Байеса к байесовским нейронным сетям. Концептуально идея следующая:

1. Мы используем диагональное нормальное распределение для аппроксимации апостериорного распределения весов модели — $q(W)$.
2. Априорное распределение весов модели так же задаётся диагональным распределением с нулевым матожиданием — $p(W)$.
3. Используя вариационный вывод, мы приходим к ситуации, когда ELBO зависит от $KL(q(W)||p(W))$. Так как оба распределения являются нормальными, то KL дивергенция считается аналитически.
4. Мотивация следующего этапа была взята из RVM — взять дисперсию априорного распределения весов модели $p(W)$ из данных. Там несложно берётся производная и всё получается красиво, кроме возможного деления $0/0$. Но сделав замену переменных, от этой беды можно уйти.

Пункты 1–3 в принципе были описаны в статье [Weight Uncertainty in Neural Networks](#). А вот четвёртый пункт я ни в книгах, ни в статьях не находил.

1 Обозначения и сокращения

$N(\mu, \sigma^2)$ — нормальное распределение

$\mathbf{x} \odot \mathbf{y}$ — поэлементное произведение (произведение Адамара) векторов

\mathcal{L} — Evidence Lower Bound (ELBO)

$KL(q||p) = \int q(\mathbf{Z}) \cdot \ln \frac{q(\mathbf{Z})}{p(\mathbf{Z})} d\mathbf{Z}$ — дивергенция Кульбака–Лейблера

\mathbf{x} — вектор признаков

\mathbf{y} — вектор целевой переменной

D — датасет — пары значений $\{\mathbf{x}_i, \mathbf{y}_i\}$, где $i = 1, \dots, L$

\mathbf{W} — веса модели — случайная величина размерности M

$p(D|\mathbf{W}) = \prod_{i=1}^L p(\mathbf{y}_i|\mathbf{x}_i, \mathbf{W})$ — правдоподобие (likelihood)

$p(\mathbf{W})$ — априорное распределение весов модели (prior)

$p(\mathbf{W}|D)$ — апостериорное распределение весов модели (posterior)

$p(D)$ — маргинальная вероятность датасета (evidence)

$p(\mathbf{W}, D) = p(D|\mathbf{W}) \cdot p(\mathbf{W}) = p(\mathbf{W}|D) \cdot p(D)$ — совместная вероятность весов модели и данных

$q(\mathbf{W}|\boldsymbol{\theta})$ — аппроксимация апостериорного распределения весов модели

$\boldsymbol{\theta}$ — обучаемые параметры байесовской модели

2 Постановка задачи

Задача машинного обучения с учителем в вероятностной постановке формулируется следующим образом: получить распределение вероятностей $p(\mathbf{y}|\mathbf{x}, D)$ целевой переменной \mathbf{y} для неразмеченных \mathbf{x} , используя информацию из датасета D . В случае параметрических моделей,

которыми являются нейронные сети, информация из датасета D кодируется посредством весов модели \mathbf{W} . Сделаем следующие преобразования:

$$p(\mathbf{y}|\mathbf{x}, D) = \int p(\mathbf{y}, \mathbf{W}|\mathbf{x}, D) d\mathbf{W} = \int p(\mathbf{y}|\mathbf{W}, \mathbf{x}, D) \cdot p(\mathbf{W}|\mathbf{x}, D) d\mathbf{W} = \int p(\mathbf{y}|\mathbf{W}, \mathbf{x}) \cdot p(\mathbf{W}|D) d\mathbf{W}$$

Пояснения:

- $p(\mathbf{y}|\mathbf{x}, D) = \int p(\mathbf{y}, \mathbf{W}|\mathbf{x}, D) d\mathbf{W}$, так как для любых случайных величин \mathbf{a} и \mathbf{b} справедливо $p(\mathbf{a}) = \int p(\mathbf{a}, \mathbf{b}) d\mathbf{b}$
- $p(\mathbf{y}, \mathbf{W}|\mathbf{x}, D) = p(\mathbf{y}|\mathbf{W}, \mathbf{x}, D) \cdot p(\mathbf{W}|\mathbf{x}, D)$, так как для любых случайных величин \mathbf{a} и \mathbf{b} справедливо $p(\mathbf{a}, \mathbf{b}) = p(\mathbf{a}|\mathbf{b}) \cdot p(\mathbf{b})$
- $p(\mathbf{y}|\mathbf{W}, \mathbf{x}, D) = p(\mathbf{y}|\mathbf{W}, \mathbf{x})$, так как вся информация из D отражена в весах \mathbf{W}
- $p(\mathbf{W}|\mathbf{x}, D) = p(\mathbf{W}|D)$, так как веса модели \mathbf{W} не зависят от неразмеченных \mathbf{x} , которых не было в датасете D .

В байесовском машинном обучении веса модели являются случайной величиной. Следовательно, для того, чтобы получить предсказательное распределение $p(\mathbf{y}|\mathbf{x}, D)$, мы должны усреднить ответы, взвешенные по вероятностям возможных значений $p(\mathbf{W}|D)$ от бесконечного числа моделей.

Для аппроксимации распределения ответов модели можно воспользоваться методом Монте-Карло. Идея следующая: сэмплируем конечное количество весов $\hat{\mathbf{W}}_1, \dots, \hat{\mathbf{W}}_T$ из распределения $p(\mathbf{W}|D)$ и аппроксимируем распределение $p(\mathbf{y}|\mathbf{x}, D)$ следующим образом:

$$p(\mathbf{y}|\mathbf{x}, D) \approx \frac{1}{T} \sum_{t=1}^T p(\mathbf{y}|\hat{\mathbf{W}}_t, \mathbf{x}), \text{ где } \hat{\mathbf{W}}_t \text{ — сэмпл весов модели из } p(\mathbf{W}|D)$$

Получим выражение для $p(\mathbf{W}|D)$, используя формулу Байеса:

$$p(\mathbf{W}|D) = \frac{p(\mathbf{W}, D)}{p(D)} = \frac{p(\mathbf{W}, D)}{\int p(\mathbf{W}, D) d\mathbf{W}} = \frac{p(D|\mathbf{W}) \cdot p(\mathbf{W})}{\int p(D|\mathbf{W}) \cdot p(\mathbf{W}) d\mathbf{W}}$$

Получить аналитическое решение интеграла $\int p(D|\mathbf{W}) \cdot p(\mathbf{W}) d\mathbf{W}$ можно только в очень ограниченном числе случаев. Существует возможность сэмплировать из $p(\mathbf{W}|D)$, используя методы Монте-Карло для марковских цепей (MCMC). Однако для больших датасетов и большого числа весов это практически невозможно. Альтернативным подходом к решению такой задачи является вариационный вывод — аппроксимация распределения $p(\mathbf{W}|D)$ распределением $q(\mathbf{W}|\boldsymbol{\theta})$, из которого сэмплировать намного проще.

3 Вариационный вывод

Идея вариационного вывода — сведение задачи байесовского вывода к задаче максимизации нижней вариационной границы (ELBO) \mathcal{L} , которая для распределения $q(\mathbf{W}|\boldsymbol{\theta})$ записывается следующим образом:

$$\mathcal{L}(q(\mathbf{W}|\boldsymbol{\theta})) = \int q(\mathbf{W}|\boldsymbol{\theta}) \cdot \ln \frac{p(\mathbf{D}, \mathbf{W})}{q(\mathbf{W}|\boldsymbol{\theta})} d\mathbf{W}$$

Покажем мотивацию максимизации ELBO. Запишем выражение для $KL(q(\mathbf{W}|\boldsymbol{\theta})||p(\mathbf{W}|D))$ и преобразуем его, используя тождество $p(\mathbf{W}, D) = p(\mathbf{W}|D) \cdot p(D)$:

$$\begin{aligned} KL(q(\mathbf{W}|\boldsymbol{\theta})||p(\mathbf{W}|D)) &= \int q(\mathbf{W}|\boldsymbol{\theta}) \cdot \ln \frac{q(\mathbf{W}|\boldsymbol{\theta})}{p(\mathbf{W}|D)} d\mathbf{W} = \int q(\mathbf{W}|\boldsymbol{\theta}) \cdot \ln \frac{p(D) \cdot q(\mathbf{W}|\boldsymbol{\theta})}{p(D, \mathbf{W})} d\mathbf{W} = \\ &= \ln p(D) \cdot \int q(\mathbf{W}|\boldsymbol{\theta}) d\mathbf{W} - \int q(\mathbf{W}|\boldsymbol{\theta}) \cdot \ln \frac{p(\mathbf{D}, \mathbf{W})}{q(\mathbf{W}|\boldsymbol{\theta})} d\mathbf{W} = \ln p(D) - \mathcal{L}(q(\mathbf{W}|\boldsymbol{\theta})) \end{aligned}$$

$\ln p(D)$ не зависит от θ . Следовательно, максимизируя $\mathcal{L}(q(\mathbf{W}|\theta))$, мы минимизируем $KL(q(\mathbf{W}|\theta)||p(\mathbf{W}|D))$. То есть распределение весов модели $q(\mathbf{W}|\theta)$ будет приближаться к апостериорному распределению весов модели $p(\mathbf{W}|D)$.

Преобразуем выражение для $\mathcal{L}(q(\mathbf{W}|\theta))$, используя тождество $p(\mathbf{W}, D) = p(D|\mathbf{W}) \cdot p(\mathbf{W})$:

$$\begin{aligned}\mathcal{L}(q(\mathbf{W}|\theta)) &= \int q(\mathbf{W}|\theta) \cdot \ln \frac{p(D, \mathbf{W})}{q(\mathbf{W}|\theta)} d\mathbf{W} = \int q(\mathbf{W}|\theta) \cdot \ln \frac{p(D|\mathbf{W}) \cdot p(\mathbf{W})}{q(\mathbf{W}|\theta)} d\mathbf{W} = \\ &= \int q(\mathbf{W}|\theta) \cdot \ln p(D|\mathbf{W}) d\mathbf{W} - \int q(\mathbf{W}|\theta) \cdot \ln \frac{q(\mathbf{W}|\theta)}{p(\mathbf{W})} d\mathbf{W} = \\ &= \int q(\mathbf{W}|\theta) \cdot \ln p(D|\mathbf{W}) d\mathbf{W} - KL(q(\mathbf{W}|\theta)||p(\mathbf{W}))\end{aligned}$$

Таким образом, задача байесовского вывода свелась к задаче максимизации $\mathcal{L}(q(\mathbf{W}|\theta))$ по параметрам θ :

$$\arg\max_{\theta} \mathcal{L}(q(\mathbf{W}|\theta)) = \int q(\mathbf{W}|\theta) \cdot \ln p(D|\mathbf{W}) d\mathbf{W} - KL(q(\mathbf{W}|\theta)||p(\mathbf{W}))$$

При аппроксимации апостериорного распределения параметров модели $p(\mathbf{W}|D)$ распределением $q(\mathbf{W}|\theta)$ аппроксимация предсказательного распределения $p(\mathbf{y}|\mathbf{x}, D)$ будет выглядеть следующим образом:

$$p(\mathbf{y}|\mathbf{x}, D) \approx \frac{1}{T} \sum_{t=1}^T p(\mathbf{y}|\hat{\mathbf{W}}_t, \mathbf{x}), \text{ где } \hat{\mathbf{W}}_t \text{ — сэмпл весов модели из } q(\mathbf{W}|\theta)$$

4 Задание функциональных форм распределений

Для дальнейшего вывода положим, что распределения $p(\mathbf{W})$ и $q(\mathbf{W}|\theta)$ являются нормальными с диагональными матрицами ковариации:

$$p(\mathbf{W}) = N(\mathbf{W}|\mathbf{0}, \text{diag}(\sigma_{\mathbf{p}}(\mathbf{w}))^2), \text{ где } \sigma_{\mathbf{p}}(\mathbf{w}) \text{ — вектор длины } M$$

$q(\mathbf{W}|\theta) = N(\mathbf{W}|\boldsymbol{\mu}, \text{diag}(\sigma_{\mathbf{q}}(\mathbf{w}))^2)$, где $\boldsymbol{\mu}$ и $\sigma_{\mathbf{q}}(\mathbf{w})$ — вектора длины M , которые вместе образуют вектор обучаемых параметров θ .

Априорное распределение весов модели $p(\mathbf{W})$ имеет нулевое математическое ожидание (из соображений симметрии), и среднеквадратическое отклонение $\sigma_{\mathbf{p}}(\mathbf{w})$. В классическом байесовском выводе параметр $\sigma_{\mathbf{p}}(\mathbf{w})$ должен задаваться до начала обучения, то есть являться гиперпараметром. Однако мы можем воспользоваться техникой эмпирического Байеса, то есть определить параметр априорного распределения $\sigma_{\mathbf{p}}(\mathbf{w})$ из данных.

Пусть $\boldsymbol{\alpha} = \text{diag}(\sigma_{\mathbf{p}}(\mathbf{w}))^{-2}$. Тогда $p(\mathbf{W}) = N(\mathbf{W}|\mathbf{0}, \boldsymbol{\alpha}^{-1})$.

Так как распределения $p(\mathbf{W})$ и $q(\mathbf{W}|\theta)$ являются нормальными, то $KL(q(\mathbf{W}|\theta)||p(\mathbf{W}))$ можно посчитать аналитически:

$$\begin{aligned}KL(q(\mathbf{W}|\theta)||p(\mathbf{W})) &= \frac{1}{2} \sum_{k=1}^M \left(\frac{\sigma_{q(W)_k}^2}{\sigma_{p(W)_k}^2} + \frac{\mu_k^2}{\sigma_{p(W)_k}^2} - \ln \frac{\sigma_{q(W)_k}^2}{\sigma_{p(W)_k}^2} - 1 \right) = \\ &= \frac{1}{2} \sum_{k=1}^M (\alpha_k (\sigma_{q(W)_k}^2 + \mu_k^2) - \ln (\alpha_k \cdot \sigma_{q(W)_k}^2) - 1)\end{aligned}$$

Так как в выражении $\mathcal{L}(q(\mathbf{W}|\theta))$ интеграл $\int q(\mathbf{W}|\theta) \cdot \ln p(D|\mathbf{W}) d\mathbf{W}$ не зависит от параметров распределения $p(\mathbf{W})$, то:

$$\frac{\partial \mathcal{L}(q(\mathbf{W}|\theta))}{\partial \alpha_k} = - \frac{\partial (KL(q(\mathbf{W}|\theta)||p(\mathbf{W})))}{\partial \alpha_k} = - \frac{1}{2} (\sigma_{q(W)_k}^2 + \mu_k^2 - \frac{1}{\alpha_k}) = - \frac{1}{2} (\sigma_{q(W)_k}^2 + \mu_k^2 - \sigma_{p(W)_k}^2)$$

Приравняв производную к нулю, получим:

$$-\frac{1}{2}(\sigma_{q(W)_k}^2 + \mu_k^2 - \sigma_{p(W)_k}^2) = 0$$

$$\sigma_{p(W)_k}^2 = \sigma_{q(W)_k}^2 + \mu_k^2$$

Подставив полученное выражение в $KL(q(\mathbf{W}|\boldsymbol{\theta})||p(\mathbf{W}))$, получим:

$$KL(q(\mathbf{W}|\boldsymbol{\theta})||p(\mathbf{W})) = \frac{1}{2} \sum_{k=1}^M \ln(1 + \frac{\mu_k^2}{\sigma_{q(W)_k}^2})$$

Таким образом, мы свели задачу к следующему виду:

$$\arg \max_{\boldsymbol{\mu}, \boldsymbol{\sigma}_q(\mathbf{W})} \mathcal{L}(q(\mathbf{W}|\boldsymbol{\mu}, \boldsymbol{\sigma}_q(\mathbf{W}))) = \int q(\mathbf{W}|\boldsymbol{\mu}, \boldsymbol{\sigma}_q(\mathbf{W})) \cdot \ln p(D|\mathbf{W}) d\mathbf{W} - \frac{1}{2} \sum_{k=1}^M \ln(1 + \frac{\mu_k^2}{\sigma_{q(W)_k}^2})$$

5 Репараметризация

При решении задачи оптимизации при попадании в такие области, где для какого-либо веса $\sigma_{q(W)_k} = 0$ и $\mu_k = 0$, возникает неопределенность деления $\frac{0}{0}$. Чтобы избежать этой неопределенности, и чтобы $\boldsymbol{\sigma}_q(\mathbf{W})$ была всегда положительна, сделаем следующую замену переменных:

$$\sigma_{q(W)_k} = \ln(1 + e^{\rho_k}) = \text{Softplus}(\rho_k)$$

$$\mu_k = \gamma_k \cdot \text{Softplus}(\rho_k)$$

Тогда:

$$KL(q(\mathbf{W}|\boldsymbol{\theta})||p(\mathbf{W})) = \frac{1}{2} \sum_{k=1}^M \ln(1 + \frac{\mu_k^2}{\sigma_{q(W)_k}^2}) = \frac{1}{2} \sum_{k=1}^M \ln(1 + \gamma_k^2)$$

Таким образом, задача сводится к минимизации следующей функции потерь:

$$\operatorname{argmin}_{\boldsymbol{\rho}, \boldsymbol{\gamma}} \text{Loss}(\boldsymbol{\rho}, \boldsymbol{\gamma}) = -\frac{\mathcal{L}(q(\mathbf{W}|\boldsymbol{\theta}))}{L} =$$

$$\int N(\mathbf{W}|\boldsymbol{\mu}, \text{diag}(\boldsymbol{\sigma}_q(\mathbf{W}))^2) \cdot NLL d\mathbf{W} + \frac{KL}{L}$$

где:

$$\boldsymbol{\sigma}_q(\mathbf{W}) = \text{Softplus}(\boldsymbol{\rho})$$

$$\boldsymbol{\mu} = \boldsymbol{\gamma} \cdot \text{Softplus}(\boldsymbol{\rho})$$

$$NLL = -\frac{1}{L} \sum_{i=1}^L \ln p(\mathbf{y}_i|\mathbf{x}_i, \mathbf{W})$$

$$KL = \frac{1}{2} \sum_{k=1}^M \ln(1 + \gamma_k^2)$$

6 Алгоритм обучения

Задаем шаг градиентного спуска α и инициализируем параметры распределения $q(\mathbf{W}|\boldsymbol{\theta})$ — $\boldsymbol{\rho}$ и $\boldsymbol{\gamma}$. Затем повторяем, пока не достигнем критерия остановки:

1. $\boldsymbol{\sigma} \leftarrow \text{Softplus}(\boldsymbol{\rho})$ — расчёт среднеквадратических отклонений весов
2. $\boldsymbol{\mu} \leftarrow \boldsymbol{\gamma} \odot \boldsymbol{\sigma}$ — расчёт математических ожиданий весов
3. $\hat{\mathbf{W}} \leftarrow N(0, 1)$ — сэмплирование случайных весов
4. $\hat{\mathbf{W}} \leftarrow \hat{\mathbf{W}} \odot \boldsymbol{\sigma} + \boldsymbol{\mu}$ — репараметризация

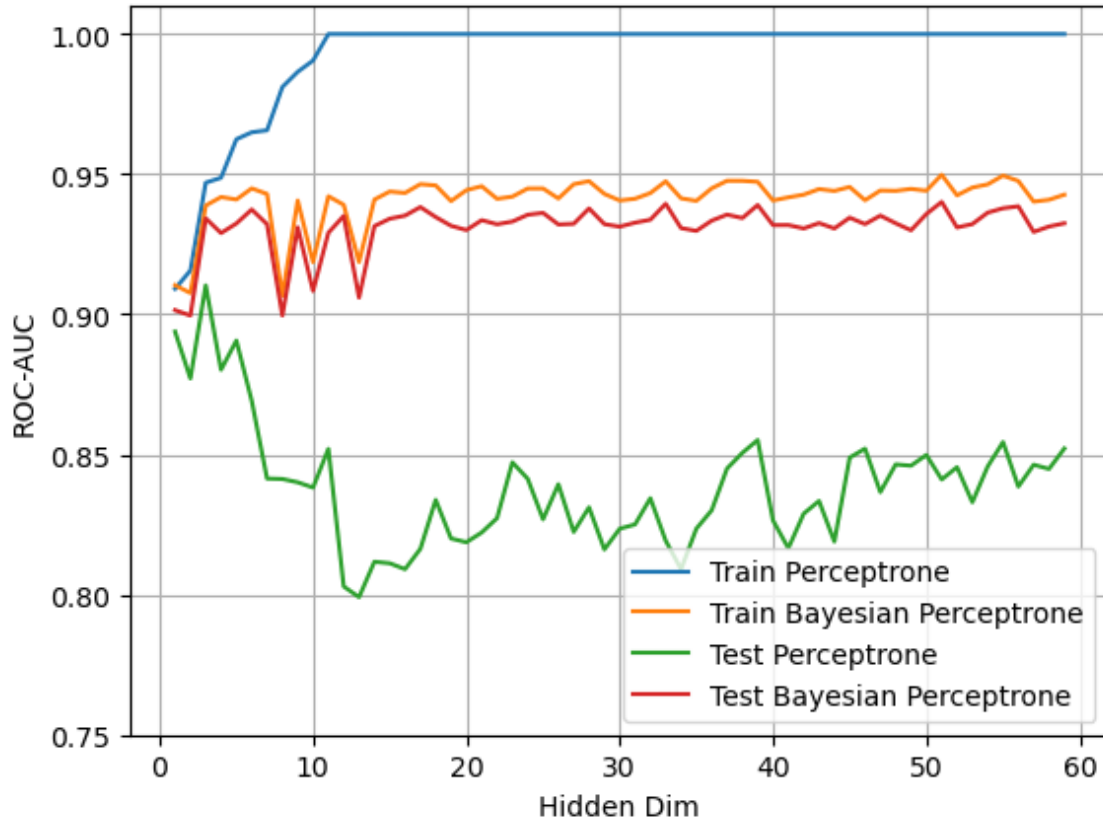


Рис. 1: Зависимость ROC-AUC от размерности скрытого состояния на тренировочных и тестовых данных

5. $nll \leftarrow -\frac{1}{L} \sum_{i=1}^L \ln p(\mathbf{y}_i | \mathbf{x}_i, \hat{\mathbf{W}})$ — расчёт среднего отрицательного логарифма правдоподобия (возможна аппроксимация по батчам)
6. $kl \leftarrow \frac{1}{2} \sum_{k=1}^M \ln(1 + \gamma_k^2)$ — расчёт KL-дивергенции
7. $l \leftarrow nll + \frac{kl}{L}$ — расчёт функции потерь
8. $\boldsymbol{\rho} \leftarrow \boldsymbol{\rho} - \alpha \frac{\partial l}{\partial \boldsymbol{\rho}}$ — обновление $\boldsymbol{\rho}$
9. $\boldsymbol{\gamma} \leftarrow \boldsymbol{\gamma} - \alpha \frac{\partial l}{\partial \boldsymbol{\gamma}}$ — обновление $\boldsymbol{\gamma}$

7 Эксперименты

Для проверки своей гипотезы я выбрал [Alzheimer's Disease Dataset](#). Данные были разбиты на тренировочную и тестовую часть в пропорции 80 на 20. В качестве архитектуры была выбрана полносвязная нейронная сеть с одним скрытым слоем и функцией активации ReLU. То есть:

$$z = \text{ReLU}(\text{matmul}(x, W_1))$$

$$y = \text{Sigmoid}(\text{matmul}(z, W_2))$$

Размерность скрытого состояния z варьировалась от 1 до 60. Для каждой размерности обучались 2 модели - классическая (без регуляризации) и байесовская. Для каждой модели производилась оценка ROC-AUC на тренировочной и тестовой выборках. На рисунке 1 представлены результаты экспериментов

8 Выводы

По результатам работы можно сделать следующие выводы:

- с ростом сложности модели байесовская нейронная сеть не переобучилась;
- значение ROC-AUC на тестовой выборке имеет очень высокую корреляцию со значением ROC-AUC на тренировочной выборке (0.97 по Пирсону). Следовательно, для подбора гиперпараметров можно ориентироваться на метрики, полученные по тренировочной выборке. Это даёт нам возможность отказаться от деления на тренировочную и валидационную выборки для подбора гиперпараметров.

Так же стоит отметить, что данный подход переносится на другие архитектуры нейронных сетей (рекуррентные, свёрточные, трансформеры).

Имплементация данного подхода была выполнена с использованием PyTorch. Весь исходный код для проведения экспериментов размещён по адресу <https://github.com/dimabasow/bayesian-neural-networks>.